Alejandro Ventura

Universidad del Pacífico



Análisis textual con Python

Curso presencial de 110 minutos

12 de octubre de 2026
Por invitación de Beatriz Rodríguez Santizabal

Cientos de discursos

Fragmento A

> *«El éxito alcanzado por la Empresa Estatal de Petróleo justifica por eso plenamente la decisión de autorizarle a emprender diversos e importantes programas, entre los que destacan los siguientes:»*

¿Qué intervención describe? Señala una expresión que sostenga tu interpretación.

Fragmento B

> *«Esto supone que el Estado concentre su acción en el diseño de políticas generales y en la atención de servicios básicos y traslade al sector privado, con algunas excepciones, la responsabilidad del desarrollo de la producción y la comercialización de bienes y servicios, el que se dará bajo condición de competencia y de mercado.»*

¿Qué cambia respecto de A? ¿Qué información falta?

Nuestra pregunta

¿Qué instrumentos de intervención económica aparecen en estos mensajes y qué diferencias podemos sostener al comparar palabras y leer fragmentos?

Alcance de la evidencia

Estudiaremos lo que los discursos declaran. Para saber qué se ejecutó hacen falta otras fuentes.

Tu entrega individual reunirá un resultado numérico, evidencia textual y una conclusión con límites.

Enfoques de análisis textual

Contenido Categorías y reglas de interpretación. Berelson sistematiza el enfoque en 1952.

Computación Conteos y diccionarios a escala. General Inquirer es un ejemplo.

Modelos de lenguaje Clasificación mediante instrucciones. Un ejemplo de aplicación aparece en 2023.

Los enfoques pueden combinarse. ¿Qué aporta cada uno a nuestra pregunta?

(Berelson, 1952; General Inquirer, s.f.; Gilardi et al., 2023)

Instrumentos económicos

Rol	**Instrumento dominante**
Empresario	Propiedad y control estatal de producción.
Regulador	Reglas generales y supervisión de mercados.
Facilitador	Promoción selectiva sin requerir propiedad estatal.

Una palabra aislada puede tener varios sentidos. La investigación también distingue asistencial y no aplica.

Clasificación y procedencia

Antes de revelar la procedencia, registra para A y B:

1. Una clasificación provisional.
2. La expresión que la respalda.
3. Una duda o información que falta.

Puedes justificar evidencia insuficiente. Conserva tu decisión para revisarla al final.

Python, bibliotecas y Colab

Python	Lenguaje para escribir instrucciones.
Biblioteca	Herramientas reutilizables para una necesidad.
Colab	Entorno donde editamos el notebook y ejecutamos Python.

Cada estudiante trabaja y guarda su propia copia. Puedes discutir con otras personas y ejecutar en tu laptop.

Una variable y su resultado

Una variable conserva un valor. = asigna y las comillas delimitan texto.

```
saludo = "Estoy explorando textos"
print(saludo)
```

Cambia el saludo y vuelve a ejecutar. ¿Dónde aparece tu modificación?

Carga de la tabla

pandas permite leer y explorar tablas.

1. Ejecuta Preparación con la carga incluida.
2. Ejecuta la tabla de documentos.
3. Identifica fecha, orador y audiencia.

¿Qué representa una fila? ¿Todas tienen la misma extensión?

Documentación oficial de pandas: (pandas, s.f.).

Seis mensajes seleccionados

Gobierno	**Mensajes del 28 de julio**
Leguía	1920 y 1921
Velasco	1969 y 1970
Alberto Fujimori	1991 y 1992

La regla de selección precede al conteo. Audiencias y ocasiones difieren. **Al minuto 36:** copia propia y seis filas de documentos disponibles.

PDF del archivo oficial del Congreso. Copias trazables a `v1.0-ccl`.

Texto original y texto para conteos

Original, extracto literal:

«No ha descuidado mi Gobierno el incremento de la agricultura y ganadería.»

Versión para conteos:

no ha descuidado mi gobierno el incremento de la agricultura y ganadería

¿Qué cambió? ¿Qué significa conservar «no»?

Leguía, 1921, PDF p. 11, unidad u00126.

Tabla de frecuencias

Antes de ejecutar, predice qué palabras aparecerán primero.

```
numero_palabras = 10
```

Cambia 10 a 8 y vuelve a ejecutar.

- `Counter` cuenta cada forma exacta.
- El ranking puede ocultar palabras frecuentes.
- El denominador conserva todas las palabras procesadas.

¿Qué cambió en la tabla y qué permaneció igual?

Predicción sobre competencia

Compararemos Leguía de 1921 y Alberto Fujimori de 1991.

1. ¿Cuál tendrá más menciones absolutas?
2. ¿Cuánto puede explicar la extensión del mensaje?
3. ¿La palabra describirá el mismo concepto?

Escribe tu predicción antes de ejecutar. Puedes cambiar la palabra y los documentos.

Menciones por 1.000 palabras

$$\text{Tasa} = 1\,000 \times \frac{\text{menciones de la palabra}}{\text{palabras del documento procesado}}$$

El denominador incluye las palabras ocultas solo del ranking. La tasa describe presencia léxica. La clasificación de roles requiere interpretar las unidades.

Conteos y tasas de competencia

Mensaje	Menciones	Palabras	Por 1.000	
Leguía 1921	2	4.527	0,442	¿Qué cambió
Fujimori 1991	11	23.348	0,471	

al considerar la extensión? ¿Qué falta comprobar en el original?

Datos didácticos. Forma exacta, con tildes. Tasas redondeadas a tres decimales.

Dudas y recuperación

Al minuto 74: comparación disponible y denominador comprendido.

- Si falta una variable, vuelve a Preparación.
- Recuperación vuelve a cargar y recalcula tu consulta.
- Si reiniciaste el entorno, ejecuta Preparación primero.

Conserva la tabla si el gráfico retrasa el recorrido. La persona de apoyo ayuda a retomar la ejecución individual.

Palabras en contexto

¿La palabra significa lo que supusimos? Buscaremos en el texto original y conservaremos negaciones y signos.

1. Predice un uso de la palabra.
2. Localiza sus coincidencias.
3. Amplía la ventana y lee la unidad completa.

Amplitud del contexto

```
amplitud_contexto = 100
```

Cambia 100 a 180. El número indica caracteres a cada lado. Selecciona dos filas de documentos distintos y recupera sus unidades completas. Guarda el identificador, la página y el fragmento. El visor del PDF permite comprobar el original.

Dos usos de competencia

Leguía, 1921:

> *«cuya competencia se ha evidenciado en la campaña que, para extirpar la fiebre amarilla, desarrollóse en el norte de la República»*

Alberto Fujimori, 1991:

> *«el que se dará bajo condición de competencia y de mercado.»*

¿Qué significado tiene cada uso? ¿Qué cambia en tu interpretación?

Leguía: `u00126`, p. 11. Fujimori: `u14275`, p. 10. Extractos literales.

Conclusión y evidencia

1. ¿Qué diferencia numérica encontraste?
2. ¿Qué muestran tus dos fragmentos?
3. ¿Qué parte de tu hipótesis mantienes o revisas?
4. ¿Qué afirmación restringe tu limitación?

Al minuto 90: resultado numérico y dos fragmentos identificados.

Contraste con etiquetas existentes

Ejemplo	Primaria del modelo	Confianza	
A, Velasco 1970	empresario	alta	¿Coincides
B, Fujimori 1991	regulador	media	

con el modelo? Justifica tu decisión con el instrumento descrito y el contexto.

Etiquetas existentes, `v1.0-ccl`. Confianza categórica, no probabilidad calibrada.

Límites de las etiquetas

- El segundo anotador fue otro modelo de lenguaje.
- La referencia de 30 unidades contiene un caso empresario y uno regulador.
- Las métricas por clase rara tienen poco soporte.

La interpretación requiere revisión. Conteos, roles y actuación efectiva responden a preguntas diferentes.

Documentación de anotación y decisiones del proyecto, versión congelada.

Entrega individual sin calificación

Tu notebook debe contener:

1. Una tabla o gráfico con denominador.
2. Una conclusión vinculada al resultado.
3. Dos fragmentos originales identificados.
4. Una limitación y su consecuencia.
5. Una aplicación a documentos de tu carrera.

Conserva también tu predicción, modificación de código y contraste manual con el modelo.

Documentos de tu carrera

Área	Documentos y preguntas posibles
Derecho	Contratos y normas: obligaciones y excepciones.
Economía	Noticias y discursos: instrumentos declarados.
Finanzas	Reportes: cómo se describen riesgos.
Administración e Ingeniería Empresarial	Reportes y reclamos: prioridades y problemas.
Ingeniería de la Información	Encuestas abiertas: patrones y contexto.

¿Qué metadatos necesitarías para comparar tus documentos?

Guardado y cierre

Guarda tu copia y descarga el notebook con respuestas y salidas visibles. `apellido_nombre_analisis_textual.ipynb` Súbelo a

la carpeta de Drive indicada y comprueba que aparece. ¿Qué

decisión puedes modificar? ¿Qué afirmación todavía no permiten tus datos?

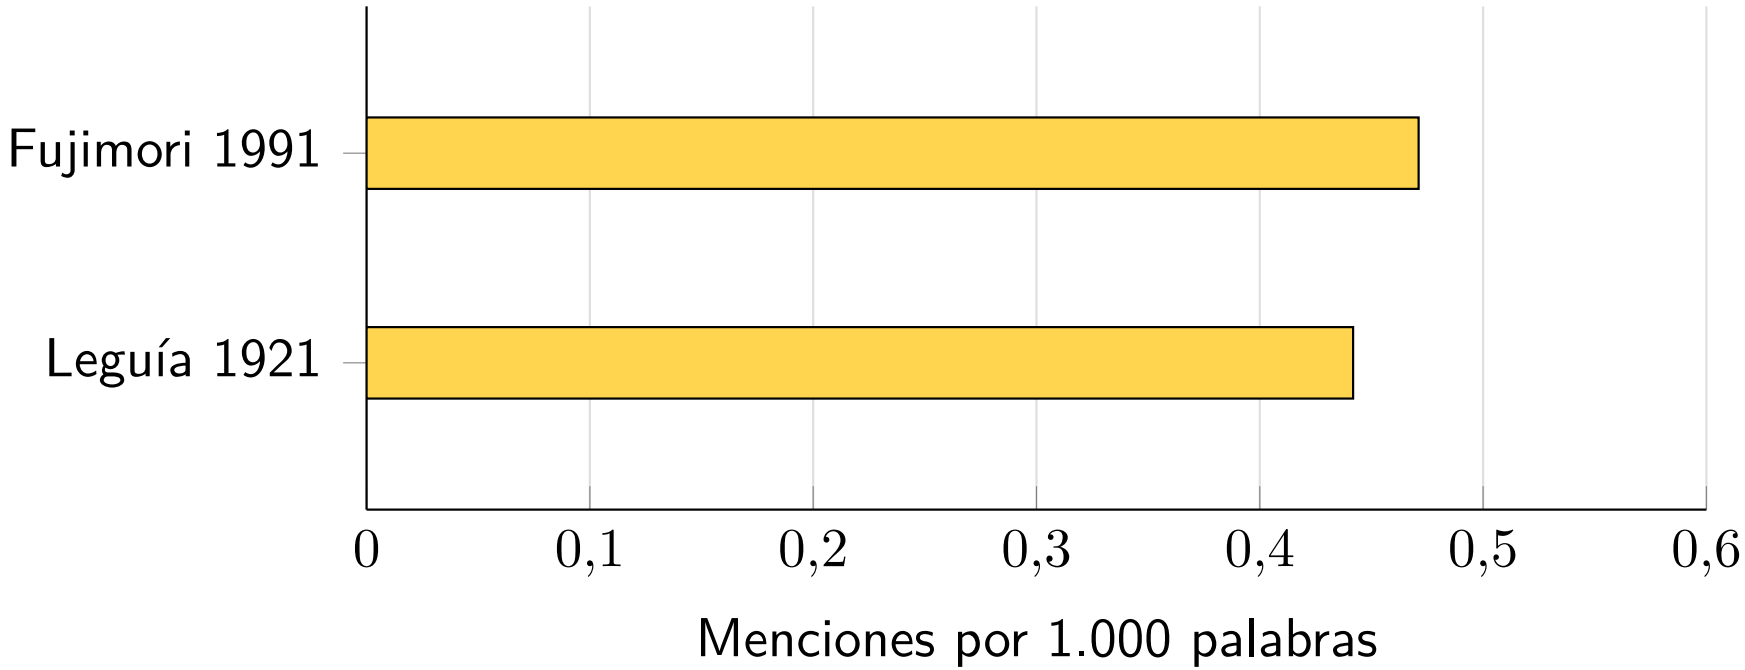
Denominadores para preguntas distintas

Medida	Denominador
Tasa de palabra	Palabras procesadas del documento.
Incidencia productiva	Todas las unidades oficiales seleccionadas.
Mezcla de roles productivos	Solo unidades empresario, regulador y facilitador seleccionadas.

Proyecto completo: 22.365 unidades oficiales y 6.899 productivas.

Selección didáctica: 619 unidades. Sus resultados tienen alcances distintos.

Gráfico de la consulta inicial



Forma exacta: competencia. Datos didácticos, consulta inicial.

Desafío opcional

Después de completar la entrega:

1. Predice qué pasará al retirar un documento.
2. Ejecuta el desafío del notebook.
3. Explica el cambio de selección y denominador.

La tasa conjunta divide la suma de menciones por la suma de palabras. No promedia tasas sin atender a la extensión.

Procedencia de ejemplos y adaptaciones

- A: Velasco 1970, `u11860`, PDF p. 10.
- B: Fujimori 1991, `u14275`, PDF p. 10.
- Polisemia: Leguía 1921, `u00126`, PDF p. 11.

PDF públicos del Museo del Congreso. Copias, unidades y etiquetas del proyecto `v1.0-ccl`. La progresión pedagógica adapta los materiales locales de análisis textual en R a una práctica propia en Python.

Referencias del análisis textual


Berelson, B. (1952). *Content Analysis in Communication Research*. Free Press.


Grimmer, J., & Stewart, B. M. (2013). Text as Data: The Promise and Pitfalls of Automatic Content Analysis Methods for Political Texts. *Political Analysis*, *21*(3), 267-297. https://doi.org/10.1093/pan/mps028

Referencias de automatización



General Inquirer. (s.f.). *Inquirer Home Page*. Harvard University. Consultado el 11 de octubre de 2026, desde https://inquirer.sites.fas.harvard.edu/



Gilardi, F., Alizadeh, M. M., & Kubli, M. (2023). ChatGPT outperforms crowd workers for text-annotation tasks. *Proceedings of the National Academy of Sciences*, *120*(30), Artículo e2305016120. https://doi.org/10.1073/pnas.2305016120

Documentación de herramientas

- Google. (s.f.). *Colab Frequently Asked Questions*. Consultado el 11 de octubre de 2026, desde https://research.google.com/colaboratory/faq.html
- Matplotlib. (s.f.). *Pyplot tutorial*. Consultado el 11 de octubre de 2026, desde https://matplotlib.org/stable/tutorials/pyplot.html
- pandas. (s.f.). *Getting started tutorials*. Consultado el 11 de octubre de 2026, desde https://pandas.pydata.org/docs/getting_started/intro_tutorials/index.html